

Nomes dos Alunos:

10. Pesquisar sobre tipos de gráficos e sua relação com os dados

Tarefa: Pesquise e explique os seguintes tipos de gráficos:

- Gráfico de barras;
- Histograma (distribuição);
- Gráfico de linhas (evolução temporal);
- Gráfico de pizza;
- *Boxplot*;
- Gráfico de dispersão.

indicando:

- Para quais tipos de variáveis são mais adequados para cada gráfico (categóricas ou numéricas);
- Que tipo de informação cada gráfico permite visualizar;
- Em quais situações o uso do gráfico é mais indicado.

Discussão:

- Qual a importância de relacionar o tipo de gráfico ao tipo de variável?

11. Gráfico de barras aplicado ao banco de dados

Tarefa: Utilize um gráfico de barras para analisar uma variável categórica (explore outras também) do banco de dados, justificando a escolha dessa variável.

Execute o código:

```
1 import matplotlib.pyplot as plt
2
3 frequencia = df['experience_level'].value_counts()
4
5 plt.bar(frequencia.index, frequencia.values)
6
7 plt.title("Frequencia por nivel de experiencia")
8 plt.xlabel("Nivel de experiencia")
9 plt.ylabel("Quantidade")
10 plt.show()
```

Discussão:

- Qual categoria apresenta maior frequência e qual a possível explicação?
- O gráfico de barras facilita a comparação entre categorias? Explique do ponto de vista visual.
- Esse gráfico seria adequado para analisar salários? Justifique.

Análise do código:

- O que a função `value_counts()` faz na variável `experience_level`?
- Que tipo de objeto é armazenado na variável `frequencia`?
- O que representam `frequencia.index` e `frequencia.values` no gráfico?
- Qual é a função do comando `plt.bar()`?
- Para que servem os comandos `plt.title()`, `plt.xlabel()` e `plt.ylabel()`?
- O que acontece se o comando `plt.show()` não for executado?
- Como poderíamos modificar o código para ordenar as categorias de forma diferente?

12. Histograma aplicado à distribuição salarial

Tarefa: Aplique um histograma para analisar a distribuição de uma variável numérica contínua do banco de dados (ex.: `salary_in_usd`). Justifique sua escolha.

Execute o código:

```
1 import matplotlib.pyplot as plt
2
3 df['salary_in_usd'].hist(bins=30)
4
5 plt.title("Distribuicao Salarial")
6 plt.xlabel("Salario em USD")
7 plt.ylabel("Quantidade de Funcionarios")
8 plt.show()
```

Discussão:

- Como os salários estão distribuídos?
- Existe concentração em determinadas faixas salariais?
- Há indícios de assimetria ou valores extremos?
- Por que o histograma é mais adequado que o gráfico de barras nesse caso? Qual a diferença entre os dois?

Análise do código:

- O que o método `hist()` faz com os dados numéricos?
- Para que serve o parâmetro `bins`? O que acontece se mudarmos esse valor?

Obs.: Explore outras funções do `matplotlib` para personalizar o histograma.

13. Gráfico de linhas e análise temporal

Tarefa: Utilize um gráfico de linhas para analisar a evolução de uma variável ao longo do tempo (ex.: mediana salarial por ano).

Execute o código:

```
1 import matplotlib.pyplot as plt
2
3 # Agrupa por ano e calcula a mediana salarial
4 mediana_salario = df.groupby('work_year')['salary_in_usd'].median()
5
6 # Cria o grafico de linhas
7 plt.plot(mediana_salario.index, mediana_salario.values, marker='o')
8
9 plt.title("Mediana Salarial por Ano")
10 plt.xlabel("Ano")
11 plt.ylabel("Salario em USD")
12 plt.show()
```

Discussão:

- O salário mediano apresenta crescimento, queda ou estabilidade ao longo dos anos?
- O gráfico de linhas é adequado para esse tipo de análise? Por quê?
- Que fatores externos podem influenciar essa evolução?

Análise do código:

- Qual é a função do método `groupby('work_year')` neste gráfico?
- Poderíamos utilizamos `mean()` ao invés de `median()` para agregar os salários?
- Que tipo de objeto é retornado após `groupby(...).median()`?
- O que representam `mediana_salario.index` e `mediana_salario.values` no gráfico?
- Por que é importante agregar os dados por ano antes de plotar o gráfico de linhas?

14. Gráfico de pizza e proporções no banco de dados

Tarefa: Utilize um gráfico de pizza para analisar a proporção entre categorias de uma variável categórica do banco de dados.

Execute o código:

```
1 import matplotlib.pyplot as plt
2
3 # Calcula a frequencia de cada categoria
4 frequencia = df['work_setting'].value_counts()
5
6 # Cria o grafico de pizza
7 plt.pie(frequencia.values, labels=frequencia.index, autopct='%1.1f%%',
8         startangle=90)
9 plt.title("Proporcao dos Modelos de Trabalho")
10 plt.show()
```

Discussão:

- Qual modelo de trabalho é mais frequente?
- O gráfico de pizza facilita a visualização das proporções?
- Em quais situações esse gráfico pode não ser a melhor escolha?

Análise do código:

- O que faz o método `value_counts()` neste contexto?
- Qual é a função dos parâmetros `labels` e `autopct` em `plt.pie()`?
- O que representam `frequencia.index` e `frequencia.values` no gráfico?
- Por que é importante calcular a frequência antes de criar o gráfico de pizza?
- Em que situações o gráfico de pizza pode ser menos adequado para comparar categorias?

15. Boxplot e análise de dispersão dos salários

Tarefa: Utilize um boxplot para comparar a distribuição salarial entre diferentes categorias do banco de dados.

Execute o código:

```
1 import matplotlib.pyplot as plt
2
3 # Cria um boxplot comparando salarios por nivel de experiencia
4 df.boxplot(column='salary_in_usd', by='experience_level')
5
6 plt.title("Distribuicao Salarial por Nivel de Experiencia")
7 plt.xlabel("Nivel de Experiencia")
8 plt.ylabel("Salario em USD")
9 plt.show()
```

Discussão:

- Como os salários variam entre os níveis de experiência?
- Existem valores discrepantes (outliers)? Onde eles aparecem?
- Que informações o boxplot fornece que não aparecem claramente no histograma?

Análise do código:

- O que faz o parâmetro `column` no método `boxplot()`?
- Qual é a função do parâmetro `by`?
- Como poderíamos modificar o boxplot para visualizar melhor as categorias ou *outliers*?

16. Gráfico de dispersão e relação entre variáveis

Tarefa: Utilize um gráfico de dispersão para analisar a relação entre duas variáveis numéricas do banco de dados.

Execute o código:

```
1 import matplotlib.pyplot as plt
2
3 # Cria um grafico de dispersao entre ano e salario
4 plt.scatter(df['work_year'], df['salary_in_usd'])
5
6 plt.title("Salario em funcao do Ano de Trabalho")
7 plt.xlabel("Ano")
8 plt.ylabel("Salario em USD")
9 plt.show()
```

Discussão:

- Existe alguma relação visível entre o ano ('work_year') e o salário ('salary_in_usd')?
- O gráfico indica tendência, dispersão ou ausência de padrão?
- Por que gráficos de dispersão são importantes em análises exploratórias?

Análise do código:

- Qual é a função do comando `plt.scatter(x, y)`?
- O que representam cada ponto no gráfico?
- Qual é a diferença entre usar `df.plot.scatter()` e `plt.scatter()` diretamente?
- Como poderíamos modificar o gráfico para destacar melhor a tendência ou a dispersão dos dados?
- Que tipo de relação entre as variáveis podemos identificar visualmente com este gráfico?

17. Gráficos adicionais e justificativa da escolha

Tarefa: Escolha ao menos **um gráfico adicional** que considere relevante para explorar o banco de dados, justificando a escolha com base nos tipos de variáveis analisadas.

Discussão:

- Qual gráfico foi escolhido e por quê?
- Que novas informações esse gráfico revelou?
- Esse gráfico reforça ou complementa análises anteriores?